

## Processos Não Estacionários

### Testes de Raiz Unitária

#### Bibliografia Básica:

- Enders, W. *Applied Econometric Time Series*. Cap. 4.
- Bueno, R. L. S. *Econometria de Séries Temporais*. Cap. 4.
- Box, G.E., Jenkins, G. M., Reinsel, G.C. & Ljung, G. M.(2016). *Time series analysis: forecasting and control*. Cap. 4.
- Morettin, P. A. *Análise de Séries Temporais*. Cap. 5.

**Processo estocástico:** é uma coleção de variáveis aleatórias ordenadas no tempo.

**Processo Estocástico Estacionário:** média e variância são constantes ao longo do tempo; covariância depende da distância entre os valores da série.

**Processo Ergódico:** coeficiente de autocorrelação (autocovariância) tende a zero, para  $t \rightarrow \infty$ .

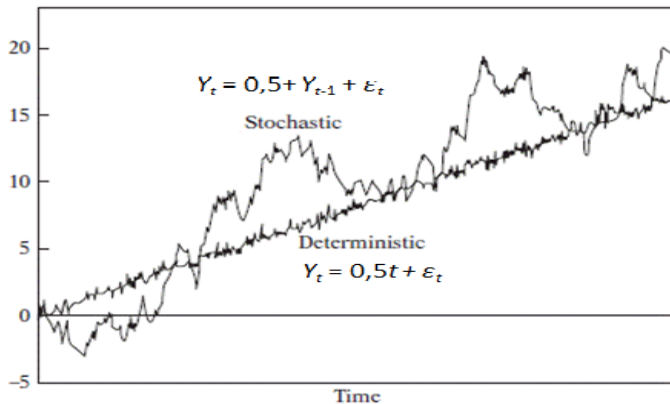
**Processo Estocástico Não Estacionário:** média e/ou variância serão dependentes do tempo.

**Processos Puramente Aleatórios**, chamado de “ruído branco”, são processos que possuem média zero, variância constante e correlação serial igual a zero:

$$\epsilon_t \sim RB(0, \sigma_\epsilon^2)$$

# Processos Não Estacionários

**Processo não estacionário** é um processo cuja média e/ou variância serão dependentes do tempo.



- Para remover a tendência determinística, deve-se estimar  $Y_t$  contra o tempo e armazenar os resíduos. Os resíduos armazenados constituem a nova série que deverá ser modelada de forma separada.
- Para remover a tendência estocástica, basta aplicar o operador diferenças.

# Processos Estocásticos Integrados

**Processo estocástico integrado:** processo estocástico que pode se tornar estacionário por meio da diferenciação.

Se um processo se torna estacionário ao se tomar sua primeira diferença dizemos que este processo é integrado de ordem um, ou  $I(1)$ .

Se o processo somente se tornar estacionário na  $d$ -ésima diferença dizemos que este é um processo integrado de ordem  $d$ , ou  $I(d)$ .

Um processo que não precisa ser diferenciado para se tornar estacionário é integrado de ordem zero, ou  $I(0)$ .

# Modelo *Random Walk* ou Passeio Aleatório

Um passeio aleatório é dado por:

$$Y_t = Y_{t-1} + \epsilon_t$$

em que  $\epsilon_t \sim RB(0, \sigma_\epsilon^2)$

Este processo é estacionário ou não?

$$E(Y_t) = E(Y_{t-1} + \epsilon_t) = \dots = E(Y_0 + \sum_{t=1}^T \epsilon_t) = Y_0$$

Temos que a esperança é constante e independe do tempo.

$$Var(Y_t) = E\{(Y_t - E(Y_t))^2\} = \dots = \sum_{t=1}^T \sigma_\epsilon^2 = T\sigma_\epsilon^2$$

A variância é, portanto, uma função crescente do tempo, logo o passeio aleatório não é um processo estacionário.

# Como identificar se a série é ou não estacionária?

1. Análise gráfica
  2. Função de autocorrelação:
    - Séries não estacionárias: fortes correlações seriais
- Exemplo: Faça a seguinte simulação no R

$$Y_t = \delta + Y_{t-1} + \epsilon_t$$

supondo  $\delta = 0$  e  $\delta = 0.2$ , com  $\epsilon_t \sim N(0, 1)$  e  $Y_0 = 0$ .

- $\delta \neq 0$ : passeio aleatório com *drift* (ou **deslocamento** ou **tendência estocástica**). Neste caso, valor médio e variância são dependentes do tempo.
- $\delta = 0$ : **tendência estocástica pura**. Neste caso, variância é dependente do tempo.
- Inspeção visual raramente permite distinguir o processo como de tendência estocástica ou tendência determinística

# Como identificar se a série é ou não estacionária?

3. Teste de Raiz Unitária ou Teste de Estacionariedade.  
Considere o modelo:

$$Y_t = \rho Y_{t-1} + \epsilon_t$$

**Raiz unitária:** Quando temos que  $\rho = 1$  aparece o problema de raiz unitária que, basicamente, é sinônimo de não estacionariedade.

Passeio aleatório, com ou sem drift, pode se tornar estacionário ao ser diferenciado, isto é:

$$Y_t = Y_{t-1} + \epsilon_t \Leftrightarrow \Delta Y_t = \epsilon_t$$



# Exemplo

Considere a série de taxa de câmbio *Euro/US\$*, no período entre jan/1999 e agosto/2006.

- a) Faça o gráfico da série e construa a função de autocorrelação;
- b) Tome a primeira diferença e construa a função de autocorrelação.

# Testes de Raiz Unitária

Considere o modelo:

$$Y_t = \rho Y_{t-1} + \epsilon_t$$

Se  $|\rho| < 1$  : série é estacionária;

Se  $\rho = 1$  : série é não estacionária;

Objetivo:

Teste de Raiz Unitária: testar  $H_0 : \rho = 1$  contra  $H_1 : \rho < 1$

## Testes que abordaremos:

1. Testes Dickey Fuller
2. Teste Dickey Fuller Aumentado – ADF
3. Teste de KPSS
4. Teste de Phillips Perron
5. Teste de DF-GLS (ERS)
6. Teste com Quebra Estrutural

# 1. Teste Dickey Fuller – DF

## Objetivo:

Testar a existência de 1 RU em  $Y_t$  quando o processo gerador da série for expresso por uma das expressões abaixo:

$$(1) \quad Y_t = \alpha + \beta t + \rho Y_{t-1} + \epsilon_t \Rightarrow \Delta Y_t = \alpha + \beta t + \gamma Y_{t-1} + \epsilon_t$$

$$(2) \quad Y_t = \alpha + \rho Y_{t-1} + \epsilon_t \Rightarrow \Delta Y_t = \alpha + \gamma Y_{t-1} + \epsilon_t$$

$$(3) \quad Y_t = \rho Y_{t-1} + \epsilon_t \Rightarrow \Delta Y_t = \gamma Y_{t-1} + \epsilon_t$$

em que  $\alpha$  e  $\beta t$  são componentes determinísticos, denominados constante ou *drift* e tendência linear, respectivamente;  $\epsilon_t$  é um ruído branco.

Hipóteses nula e alternativa:

$$H_0 : \rho = 1 \Leftrightarrow \gamma = 0 \quad (1 \text{ RU})$$

$$H_1 : \rho < 1 \Leftrightarrow \gamma < 0 \quad (0 \text{ RU})$$


■ Teste Monocaudal à esquerda

■ Estatísticas dos testes são chamadas de:

1. Modelo com constante e tendência determinística:  $\tau_\tau$
2. Modelo com constante:  $\tau_\mu$
3. Modelo sem termos determinísticos:  $\tau$

# Teste DF

Sob a hipótese nula, a distribuição do teste não é convencional, ou seja, não é igual à distribuição  $t$ , dado que  $Y_t$  não é estacionário.



**FIGURE 4.7** The Dickey-Fuller Distribution

Dickey & Fuller (1979) recalcularam os valores críticos: Tabela A, p. 488, Enders (2010)

### Empirical Cumulative Distribution of $\tau$

#### Probability of a Smaller Value

Sample Size	0.01	0.025	0.05	0.10
No Constant or Time ( $a_0 = a_2 = 0$ )				$\tau$
25	-2.66	-2.26	-1.95	-1.60
50	-2.62	-2.25	-1.95	-1.61
100	-2.60	-2.24	-1.95	-1.61
250	-2.58	-2.23	-1.95	-1.62
300	-2.58	-2.23	-1.95	-1.62
$\infty$	-2.58	-2.23	-1.95	-1.62
Constant ( $a_2 = 0$ )				$\tau_\mu$
25	-3.75	-3.33	-3.00	-2.62
50	-3.58	-3.22	-2.93	-2.60
100	-3.51	-3.17	-2.89	-2.58
250	-3.46	-3.14	-2.88	-2.57
500	-3.44	-3.13	-2.87	-2.57
$\infty$	-3.43	-3.12	-2.86	-2.57
Constant + time				$\tau_\tau$
25	-4.38	-3.95	-3.60	-3.24
50	-4.15	-3.80	-3.50	-3.18
100	-4.04	-3.73	-3.45	-3.15
250	-3.99	-3.69	-3.43	-3.13
500	-3.98	-3.68	-3.42	-3.13
$\infty$	-3.96	-3.66	-3.41	-3.12

# Teste DF no R

Para realizar o teste de Dickey-Fuller, carregue o pacote `urca`.

Em seguida use a função `UR.DF`, a qual retorna, automaticamente, os valores críticos para o teste.

No R as estatísticas são denotadas por:

$$\tau_{\tau} = \tau_3$$

$$\tau_{\mu} = \tau_2$$

$$\tau = \tau_1$$



# Significância dos Termos Determinísticos

Análise da significância dos elementos determinísticos (constante e tendência linear) por meio de testes de hipóteses conjuntos, utilizando valores críticos simulados por DF.

Dickey & Fuller (1981) sugerem as estatísticas  $F$  denominadas  $\phi_1$ ,  $\phi_2$  e  $\phi_3$  para testar hipóteses conjuntas:

$$H_0 : \gamma = \alpha = 0 \Rightarrow \Phi_1$$

$$H_0 : \gamma = \alpha = \beta = 0 \Rightarrow \Phi_2$$

$$H_0 : \gamma = \beta = 0 \Rightarrow \Phi_3$$

As estatísticas relacionadas a essas hipóteses são:

$$\phi_i = \frac{(SQRes_{restrita} - SQRes_{irrestrita})/r}{SQRes_{irrestrita}/(T - k)} \quad i = 1, 3$$

sendo  $r$  o número de restrições,  $T$  número de observações,  $k$  número de parâmetros estimados no modelo irrestrito.

# EMPIRICAL DISTRIBUTION OF

$\Phi_1$  FOR  $(\alpha, \rho) = (0, 1)$  IN  $Y_t = \alpha + \rho Y_{t-1} + e_t$

Sample size $n$	0.90	0.95	0.975	0.99
25	4.12	5.18	6.30	7.88
50	3.94	4.86	5.80	7.06
100	3.86	4.71	5.57	6.70
250	3.81	4.63	5.45	6.52
500	3.79	4.61	5.41	6.47
$\infty$	3.78	4.59	5.38	6.43

$\Phi_2$  FOR  $(\alpha, \beta, \rho) = (0, 0, 1)$  IN  $Y_t = \alpha + \beta t + \rho Y_{t-1} + e_t$

25	4.67	5.68	6.75	8.21
50	4.31	5.13	5.94	7.02
100	4.16	4.88	5.59	6.50
250	4.07	4.75	5.40	6.22
500	4.05	4.71	5.35	6.15
$\infty$	4.03	4.68	5.31	6.09

$\Phi_3$  FOR  $(\alpha, \beta, \rho) = (\alpha, 0, 1)$  IN  $Y_t = \alpha + \beta t + \rho Y_{t-1} + e_t$

25	5.91	7.24	8.65	10.61
50	5.61	6.73	7.81	9.31
100	5.47	6.49	7.44	8.73
250	5.39	6.34	7.25	8.43
500	5.36	6.30	7.20	8.34
$\infty$	5.34	6.25	7.16	8.27

## 2. Testes Dickey Fuller Aumentado – ADF

Resíduos  $\hat{\epsilon}_t$  obtidos dos modelos (1) a (3) são ruídos brancos? Teste ADF: adiciona as defasagens da variável dependente, ou seja, supõe-se que a série é gerada por um processo auto-regressivo de ordem  $p$ .

$$(4) \quad \Delta Y_t = \alpha + \beta t + \gamma Y_{t-1} + \sum_{i=1}^{p-1} \delta_i \Delta Y_{t-i} + \epsilon_t$$

$$(5) \quad \Delta Y_t = \alpha + \gamma Y_{t-1} + \sum_{i=1}^{p-1} \delta_i \Delta Y_{t-i} + \epsilon_t$$

$$(6) \quad \Delta Y_t = \gamma Y_{t-1} + \sum_{i=1}^{p-1} \delta_i \Delta Y_{t-i} + \epsilon_t$$

Inclusão de termos autorregressivos não altera a convergência das estatísticas  $\tau$ ,  $\tau_\mu$  e  $\tau_\tau$ . Portanto, usa-se nos testes ADF os mesmo valores críticos utilizados nos testes DF.

Para identificar o número de atrasos  $p$  de forma que  $\hat{\epsilon}_t \sim RB(0, \sigma_\epsilon^2)$ , usa-se:

- 1) análise das autocorrelações dos resíduos do modelo sem termos de aumento;
- 2) critérios de informação: Akaike (AIC) ou Bayesian (BIC):

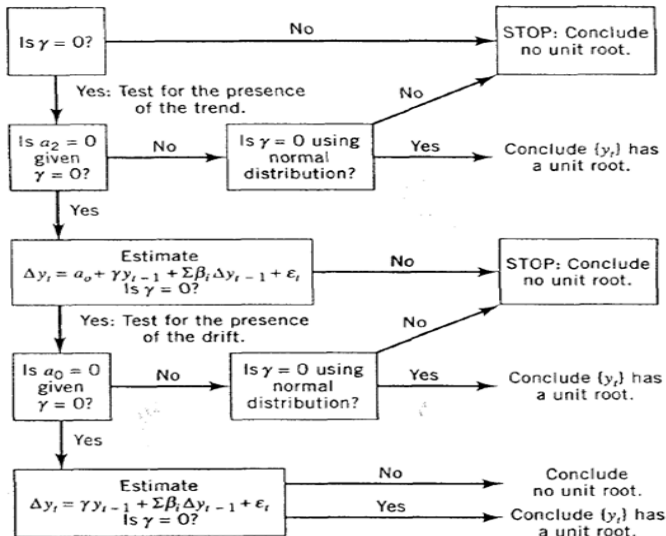
$$AIC(p) = \ln(\sigma_\epsilon^2) + p \frac{2}{T}$$

$$BIC(p) = \ln(\sigma_\epsilon^2) + p \frac{\ln(T)}{T}$$

em que  $T$  é o número de observações e  $p$  número de parâmetros.

**Figure 4.7** A procedure to test for unit roots.

Estimate  $\Delta y_t = a_0 + \gamma y_{t-1} + a_2 t + \sum \beta_i \Delta y_{t-i} + \varepsilon_t$



Verificar a existência de RU para:

1. IPCA (Fonte: IPEADATA).
2. A partir da série encaminhada por email, faça o teste ADF. Analise os resultados.